

HTR-Net : 多维度融合的 超声图像肿瘤诊断与分割系统

IEEE BIBM 2026 在投

汇报人 : BoBoowen | XX大学 · 智能医学工程专业

指导教师 : XXX 教授

 github.com/X-BoBoowen/HTR-Net

汇报目录

01 研究背景与临床痛点

02 HTR-Net 整体架构

03 语义分割模块模型改进

04 TR-Net 图像分类模块

05 GDX 集成学习临床数据融合

06 实验结果与对比分析

07 总结与贡献

研究背景与临床痛点



病灶边界模糊

超声图像信噪比低，肿瘤边缘与正常组织灰度梯度微弱，人工勾画主观性强，漏诊率高。



小病灶漏检风险

直径 $< 1\text{cm}$ 的早期肿瘤在低分辨率超声中极易被遗漏，基层医院由于设备限制风险更突出。



单一信息源局限

仅凭图像忽略了 LV-GLS、LVEF 等临床结构化指标，导致诊断准确性难以进一步突破。


临床现状：我国甲状腺癌过度诊断率已达 **87%**，急需精准辅助诊断系统。

HTR-Net 级联诊断框架

三阶段核心逻辑

- **阶段一：改进 YOLOv11 分割**
利用 C3k2_DFF 与 IEMA 实现病灶精准定位。
- **阶段二：EfficientNet TR-Net**
对提取区域进行深度迁移学习良恶性二分类。
- **阶段三：GDX 集成学习融合**
整合临床多维指标，通过 Stacking 做出最终决策。

最终性能：AUC 0.8800 | mIoU 85.7%



语义分割——模型改进

1. C3k2_DFF 双域融合


- 双分支并行：通道注意力(抑制噪声) + 空间注意力(强化边缘)。
- 动态融合：1×1 卷积生成自适应权重。

2. IEMA 注意力机制

- 特征解耦：Identity 支路保留边缘细节。
- 局部增强：放大模糊边缘的灰度梯度。

3. SCDown 轻量化

在提升性能的同时，有效控制模型参数量至 2.08M。



US image

GT mask

GenDice

GWDice

语义分割效果可视化

85.7%

+3.5%

-2.8%

mIoU 准确率

小病灶召回率提升

伪影区域误差下降

实验证明：该算法在复杂背景下展现出极强的鲁棒性，精准识别模糊边缘并有效应对伪影干扰，性能全面优于 Swin-Unet 等 SOTA 模型。

Ground truth

Prediction

Overlap

消融实验——组件有效性验证



柱状图展示 mIoU 随组件引入的提升趋势


核心结论

- **协同效应**：三组件协同(DFF+IEMA+SCDown)使 mIoU 提升 **7.85%**。
- **效率平衡**：虽然增加了注意力模块，但通过 SCDown 优化，参数量从 2.01M 控制在 **2.08M**。
- **验证充分**：共 8 组消融实验，验证了每个改进点对最终性能的独立贡献。


TR-Net 图像二分类模块

设计思路与优化

- **输入优化**：仅将分割出的病灶区域送入分类器，剔除背景冗余。
- **主干网络**：EfficientNet-B0。
- **动态扩展**：利用复合系数自适应调整深度、宽度与分辨率。
- **迁移学习**：ImageNet 预训练权重 + 自有超声数据集微调。
- **注意力辅助**：MBConv + SE 模块实现通道级特向增强。



分类性能分析结果



混淆矩阵统计

预测结果	实际良性	实际恶性
良性 (Class 0)	91 (TN)	13 (FN)
恶性 (Class 1)	17 (FP)	79 (TP)

准确率：85%

分析：识别能力高度平衡，未出现明显的类别偏向。在 300 轮训练后模型稳定收敛，无过拟合现象。

GDX 集成学习——临床数据融合



基模型互补

XGBoost (稀疏/正则) +
GradientBoosting (连续/线性) 强强联手。




堆叠集成 Stacking

使用随机森林作为元学习器，自动优化基模型权重分配。



自动化调参

GridSearchCV 搜索最优参数，早停机制防止验证集过拟合。



特征洞察：

LV-GLS 与 LVEF 相关系数 $r=0.47$ 。临床特征间存在深度关联，GDX 模型能有效提取纯图像无法捕获的非线性判别信息。

多维度融合策略：1+1+1 > 3

维度一：图像语义

改进 YOLOv11 实现病灶精准解剖定位，提取空间特征。

维度二：分类深度

TR-Net 提取病灶病理特征，输出良恶性概率向量。

维度三：结构临床

GDX 模型分析临床指标，补足生物标志物信息。




HTR-Net 融合决策中心

基于门控机制的 Stacking 堆叠，实现最终的智能诊断输出。


最终实验结果对比——全面领先

性能指标	GLS (仅临床)	TR-Net (仅图像)	HTR-Net (融合)
训练 AUC	0.7039	0.8503	0.8800
验证 AUC	0.6705	0.8181	0.8478
敏感性 (Sens)	0.7125	0.7660	0.8680
特异性 (Spec)	0.7208	0.7720	0.7480

* 对比 4 种主流多模态模型，HTR-Net 在全部 6 项指标上均处于最优水平。



模型训练稳定性验证



训练趋势分析

- **分割模型**：334 轮稳定收敛，mIoU 平稳处于 0.85 附近，损失函数下降曲线光滑。
- **分类模型**：300 轮精度稳定于 85.3%，验证集波动幅度小于 **0.5%**。
- **稳健性**：合理的学习率衰减策略有效避免了过拟合，模型具备优异的泛化能力。

工作总结与贡献

01 提出 **C3k2_DFF + IEEMA** 改进语义分割模块，mIoU 达 85.7%，超越 Swin-Unet 等主流算法。

02 设计 **GDX 集成学习模型**，实现临床数据的高效融合与自动化诊断，AUC 达 0.88。

03 独立完成数据预处理、模型架构、对比实验的**全科研闭环**，论文已投稿 **IEEE BIBM 2026**。

谢谢观看

请各位老师批评指正

✉ 联系方式：XXX@XXX.com


🐙 GitHub: github.com/X-BoBoowen/HTR-Net

Image Sources




https://www.mdpi.com/engproc/engproc-84-00066/article_deploy/html/images/engproc-84-00066-g002-550.jpg

Source: www.mdpi.com




https://www.mdpi.com/remotesensing/remotesensing-17-03996/article_deploy/html/images/remotesensing-17-03996-g010-550.jpg

Source: www.mdpi.com




https://www.mdpi.com/information/information-16-00444/article_deploy/html/images/information-16-00444-g001.png

Source: www.mdpi.com




https://miro.medium.com/1*UaXdZDf0FGERO-3J0Mr9lQ.png

Source: blog.stackademic.com



<https://www.frontiersin.org/files/Articles/1799144/xml-images/fdgth-08-1799144-g002.webp>


Source: www.frontiersin.org



<https://machinelearningmastery.com/wp-content/uploads/2014/11/ROC1.png>


Source: machinelearningmastery.com

Image Sources



<https://api.wandb.ai/files/mostafaibrahim17/images/projects/37042936/4cdebc09.png>

Source: wandb.ai



https://www.mdpi.com/diagnostics/diagnostics-13-03595/article_deploy/html/images/diagnostics-13-03595-g006-550.jpg

Source: www.mdpi.com